01 / 修订版 v2.0

Hermes + 双 CLI 编排架构与证据验收

Codex CLI 编码 · Claude Code CLI 审查

中文技术设计 | 2026 年 10 月 9 日 | 基于原版 10 页方案修订

推荐架构

选择 Hermes 作为可替换的智能协调入口；以轻量 Workflow Controller 强制管理流程，由 Codex CLI 和 Claude Code CLI 完成编码、调试与技术审查。先验证双 CLI 闭环，再接入 Hermes。

本次补充的核心答案

需求充分性依靠可执行的任务契约；实现正确性依靠与问题对应的验收证据；Review 发现必须核实；模型置信度仅作提示。自动化可以受预算约束地结束，但不能因此宣称问题已解决。

关键问题	设计选择
谁判断完成?	控制器依据已冻结的验收规则和证据推进状态；Hermes 可建议，不能绕过门禁。
如何处理不确定?	PASS / FAIL / UNKNOWN 表达验收结论；UNKNOWN 是合法的自动化终态。
如何避免空转?	轮次、总时间、单次时限、用量与成本共同限制；无进展、振荡或证据矛盾时停止。
CLI-only 如何落实?	不依赖 Codex SDK、Claude Agent SDK 或 App Server；仅用受控 CLI 子进程。

本文是待实施方案，不表示系统已部署或已通过实战评测。阈值、接口和流程为设计建议；官方能力与本机只读核对范围见末尾。

02 / 保留原文设计，明确变更

修订范围与阅读导航

原版《Hermes 纯协调层：Codex CLI 与 Claude Code CLI 执行架构》已在用户 Downloads 及此前 Work 会话输出目录找到，原文为 10 页。新版依据其生成源文件重排，保留会话映射、受控 Executor、worktree、只读审查、固定 SHA、持久化恢复、权限与故障注入设计。

原版要点	v2 修订
Hermes 决定何时停止	改为 Hermes 提交建议；控制器执行硬门禁，人工裁决业务歧义。
测试通过 + Review 无阻断	增加需求覆盖、独立验收、有效性核查与未决证据检查。
BLOCKED / FAILED 等状态	拆分运行状态、验收结论和停止原因；预算耗尽不会伪装成质量失败。
默认最多 3 轮审查修复	统一试点为最多 3 个候选版本、2 次修复、3 次 Review；明确计数语义。
可选 App Server 适配器	本方案不纳入实现依赖，以满足当前 CLI-only 约束。

阅读导航（章节编号与页码对应）

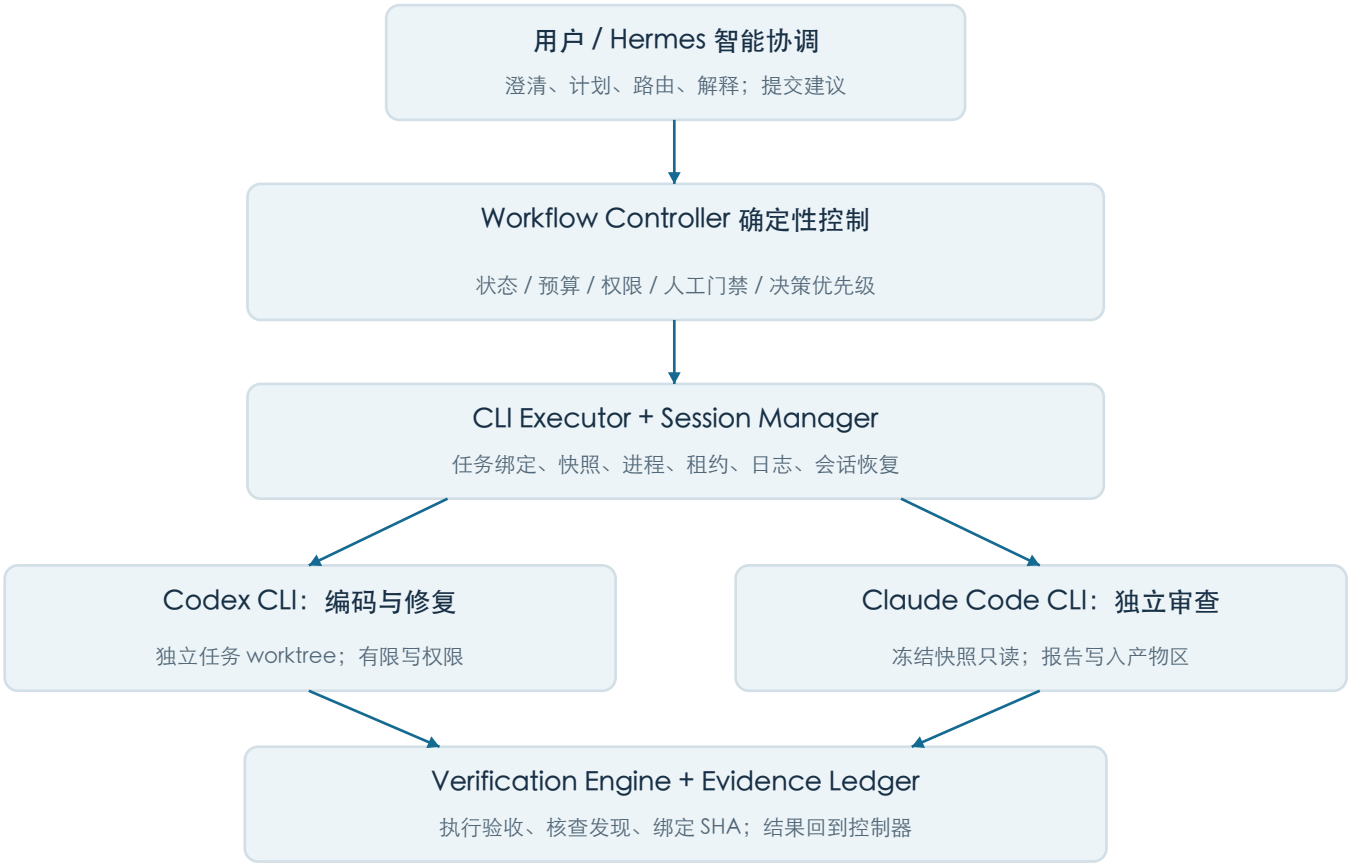
03 整体架构 04 选型与 CLI-only
05 需求充分性 06 验收矩阵 07 实现有效性
08 Review 核实 09 Review 质量评估 10 证据框架
11 置信度局限 12 决策规则 13 状态与 UNKNOWN
14 预算 15 进展与收敛 16 人机协同
17 CLI 会话 18 隔离与快照 19 Executor 契约
20 持久化恢复 21 完整案例 22 分阶段落地
23 系统验收 24 风险与交付 25 来源与核对说明

两条必须分开的结论

“流程可靠结束”不等于“实现已正确”；“未发现缺陷”不等于“没有缺陷”。本设计分别记录运行事实、验证证据与业务结论。

03 / 智能建议 + 确定性控制 + CLI 执行

整体架构与职责边界



各层职责

Hermes：整理需求、提出拆分与执行建议、解释证据、向用户汇报。其自身需要合法可用的模型推理入口；是否允许这一入口，必须在落地前核实。

Controller / Executor：校验任务契约与权限，执行状态转换，计算预算，管理会话和进程，拒绝过期结果。它们不通过语言模型生成源码，也不把模型文本当可执行命令。

Codex / Claude Code：默认编码与审查分离，按任务明确角色。Verification 使用已登记的测试、静态检查、复现器和人工反馈验证证据；需要额外模型技术判断时仍通过 CLI，受同一预算约束。

纯协调层的落实方式

Hermes 仅调用结构化编排工具，不持有源码写权限；Controller 有最终状态转换权。工具白名单配合独立系统身份、只读挂载或沙箱落实边界，不能仅靠 Prompt 与 Skill。

04 / 以 CLI-only 和维护成本为选型依据

为何选择 Hermes，而非 Open SWE

Hermes 官方仓库提供 Codex 与 Claude Code 委派 Skill；Open SWE 官方说明其基于 Deep Agents 与 LangGraph，提供研发执行和集成能力 [1][2][5]。据此，本方案推断：保留双 CLI 的原生执行循环，Hermes + 轻量控制器更贴合当前约束。

维度	Hermes + Controller	Open SWE
执行路径	以 CLI 进程适配器实现派单，复用 CLI 会话。	默认研发执行体系建立在 Deep Agents 上。
需要自行补充	可靠状态机、验收规则、预算、发现核实。	CLI-only 适配与边界需单独验证；业务验收策略仍需定义。
重复循环风险	限定 Hermes 为协调者，禁止逐条指挥编码。	再嵌套双 CLI 可能增加执行循环、上下文和恢复复杂度。
当前选择	选择为目标协调层；第一阶段可先不接入。	暂不引入；借鉴其 CI、PR 与反馈工作流。

CLI-only 必须明确约束范围

范围 A：只有工程执行必须走 CLI。 Hermes 可使用独立、获准的协调模型入口，架构可按本文实施。

范围 B：所有模型推理都只能经过两个 CLI。 不能因 Hermes 有委派 Skill，就认定其协调推理也满足限制。第一版采用纯控制器 + 双 CLI；未来若接入 Hermes，需验证其实际 runtime、鉴权及约束符合要求。

没有 Codex SDK 并不构成与 Open SWE 的逻辑冲突；问题在于现成执行路径是否匹配、要改造多少、谁负责维护。不能仅凭“开源”推断适配现成，也不能把 Open SWE 自带 CLI 等同于 Codex/Claude CLI 适配器。

本选型不宣称 Hermes 更可靠或更省 Token；需要相同任务集评测。双 CLI 的登录、额度与自动化适用规则按实际账号验证，不假定订阅涵盖所有调用。

05 / Requirement Gate

需求充分性：能否开始实施

“充分”不是文本够长，而是关键决策和验证预期已经明确。Hermes 可以将口头需求整理为契约草案；控制器检查必填项、冲突与未决阻断项，用户确认业务含义。

契约字段	应回答的问题
目标与现状	用户遇到什么问题？如何复现？期望行为与当前行为是什么？
范围与非目标	哪些模块、接口和人群在范围内？哪些改动明确不做？
约束与风险	兼容性、性能、数据、依赖、允许修改范围及授权边界是什么？
验收与反例	如何观察成功？正常、异常、边界和回归场景分别是什么？
环境与资源	基线 SHA、依赖、测试数据、可用验证环境、预算和时限是否齐备？
未决项与假设	哪些未知会改变方案或验收？谁决定？假设是否可逆且有记录？

按影响澄清，而非一次问完所有问题

阻断歧义：两种合理解释导致不同数据语义、权限或验收结果。先澄清，不进入实现。**可逆细节**：沿用仓库规范或显式假设，继续低风险工作。需求不完整时仍可开展只读调查和最小复现，但不能自行补写关键业务决策。

示例：导出“所有订单”

必须澄清“所有”是否包含其他租户、软删除记录与时间边界；文件名格式通常可沿用项目惯例。前者影响数据安全和验收，后者通常不应阻断调查。

冻结与变更

实施前保存 requirement_version 和 acceptance_version。需求变化后创建新版本，分析影响并重新验收；编码 Agent 不能为让结果通过而自行弱化标准。输入检查通过仅代表“可开始”，不代表已完全理解所有隐含需求。

06 / 需求 → 场景 → 证据

验收标准：让“完成”可观察

每条验收项包含编号、业务意图、前置条件、输入与操作、可观察结果、验证方法、阻断等级和判断责任人。必需项默认全部满足；不能用综合平均分抵消某条关键失败。

订单 CSV 导出示例	可执行预期	证据
AC-01 功能	租户 A 导出所选区间订单；ID、金额与筛选结果一致。	固定数据集 + 输出解析比对。
AC-02 权限	租户 A 的结果不含租户 B 数据；未登录请求被拒绝。	双租户集成测试 + 未授权请求。
AC-03 边界	空集、日期边界及特殊字符满足已确认约定。	参数化场景与文件内容断言。
AC-04 回归	原筛选与分页行为保持契约规定的语义。	基线回归测试与接口契约检查。
AC-05 体验	用户可发现导出入口并理解处理状态。	目标环境演示 + 业务负责人确认。

先冻结“判题依据”，再生成实现

编码 Agent 可以补充单元测试，但业务预期应来自用户确认的契约和独立样例。关键断言、验证脚本和测试数据放入控制器管理的验收区；若必须改标准，记录人工决策和新版本后重新跑验收。

不同任务使用不同证据

Bug 修复优先最小复现的修复前失败、修复后通过；重构强调行为等价和回归；性能任务固定数据规模、机器与统计方法；界面任务保留操作步骤和截图，但截图不能替代交互与权限测试。

Definition of Done

当前候选 SHA 的必需验收项均有有效通过证据；无未决阻断发现；要求的人工验收已完成；交付包可复查。合并、发布等外部动作按任务约定另行记录。

07 / Verification 的有效性

实现是否真正解决了问题

测试全绿可能意味着测试没有覆盖问题。验证必须回到原始失败场景、真实调用路径和业务结果，不能只检查新函数是否按实现者自己的预期工作。

验证层	要证实什么	典型证据
原问题复现	失败确实存在，输入和环境已知。	基线失败日志、复现步骤、固定数据。
修复效果	相同条件下结果符合需求。	候选版本重跑、输出比对、端到端路径。
副作用控制	没有破坏已知关键行为。	相关回归、接口兼容、异常与权限检查。
环境适用	验证环境足以代表目标场景。	依赖锁、配置、数据规模、平台记录。
业务验收	自动化难表达的意图得到确认。	指定责任人审阅、演示反馈与结论。

证据也需要验证

Controller 检查执行命令与策略一致、测试实际被发现并执行、没有异常跳过、报告可解析、退出状态合理、日志完整、快照匹配。0 个测试、被禁用的关键断言、仅有 Agent 摘要或无法定位原始日志，都不构成 PASS。

失败应分类

行为失败：有效场景得到错误结果，支持 FAIL。**环境失败**：数据库不可用、依赖缺失或运行超时，通常支持 UNKNOWN。**既有失败**：基线已失败且未被本次改动扩大，记录归因；是否允许豁免由既定政策或人工决定，不能自动忽略。

验证不等于证明全部正确

通过只对已声明的需求版本、场景、环境和提交有效。不能将局部测试通过扩展为所有输入、生产环境或未来版本的正确性保证。

08 / Finding 是待验证的主张

Review 发现核实与误报处理

Claude Code 独立读取固定快照和验收契约，报告文件位置、触发条件、影响、因果链、证据与反例。Review 不以“必须发现若干问题”为目标，也不能把未给证据的猜测直接变成阻断修复任务。

发现状态	判定方式	后续动作
CONFIRMED	有效复现、明确的契约违反，或可审计的静态因果证据。	按实际影响定级；进入修复或已授权豁免流程。
REFUTED	同一前提下出现可复核反证，或发现前提不成立。	保存反证与判定理由，防止反复重报。
UNRESOLVED	缺必要环境、前提不明、证据冲突或难以复现。	不当作已修复或误报；关键项升级人工或 UNKNOWN。
DUPLICATE	与既有发现为同一根因和触发条件。	关联原 ID，不重复消耗修复轮次。

核实顺序

① 校验文件、行号和 reviewed_sha。② 查验违反哪条需求或工程约束。③ 优先执行最小复现；测试在隔离验证区运行。④ 无法动态复现时检查静态因果链与反例。⑤ 保存证据和判定者；必要时人工裁决。

防止审查者与编码者互相“说服”

编码者声称“不会发生”不等于反证；审查者反复强调“很严重”不等于证据。针对一个争议最多增加一次有明确目标的核实活动；仍未解决则按风险升级。更换模型不保证独立性，多个模型赞同也不能代替复现。

纯风格建议通常不阻断，除非违反已冻结规则。不能因修复成本低就无条件接受误报；无必要修改可能引入新的缺陷。发现被确认后，修复仍需重跑对应验收与相关回归。

09 / 没有缺陷真值，就没有可信召回率

Review 发现率：如何评估

线上代码中的缺陷总数通常未知，因此“报告了很多问题”不能证明发现率高，“没有报告”也不能证明代码无缺陷。需要建立带人工真值的任务集，在相同快照、上下文和预算下比较。

指标	定义与解释
查准率 Precision	TP / (TP + FP)：已判定报告中有多少真实问题。示例：8 个真问题、2 个误报，查准率 80%。
召回率 Recall	TP / (TP + FN)：已知真实缺陷中发现了多少。示例：真实缺陷 20 个、发现 8 个，召回率 40%。
未决率	UNRESOLVED / 全部去重报告；必须单列，不能把未决排除后只展示高查准率。
严重缺陷召回	对已知高风险缺陷单独计算召回；不要让大量低影响发现掩盖关键漏报。
修复净收益	确认缺陷被消除的数量与影响，同时记录修复引入的回归和核实成本。

构建评测集

从历史缺陷、已确认 Review、真实失败案例收集任务；补充人工植入的代表性缺陷与正确对照。由人工维护根因和可接受等价发现，按根因匹配去重。合成缺陷适合测能力边界，但不代表生产缺陷分布。

用可比实验验证多 Agent 的价值

比较 Codex 单独完成、Codex 自审、Codex + Claude 独立审查三条路径；使用相同验收与预算，保留未通过任务和人工介入率。重复运行处理随机性，报告样本数、任务类型、波动与成本，而不是只挑成功案例。

术语不要混淆

“报告中的误报占比”是 FP / (TP + FP)。统计意义的 False Positive Rate 是 FP / (FP + TN)，而代码审查通常难定义所有真负例 TN；本文不把两者等同。

10 / 可追溯、可复核、可过期

证据驱动 Verification Framework

证据账本是唯一事实索引，保存原始产物引用和上下文。LLM 负责解释；Controller 负责核对来源、版本、完整性和适用范围。每次决策都必须列出使用了哪些证据、还缺哪些证据。

证据类型	证明范围	局限
运行事实	命令、执行时间、退出状态、实际测试数。	进程正常结束无法证明业务正确。
行为证据	特定输入下的输出、复现、集成与回归结果。	覆盖不完整，环境与数据可能偏离生产。
静态证据	可检查的调用路径、类型约束、权限逻辑。	工具和人工推理仍可能错误或缺上下文。
人工判断	需求解释、体验验收、风险接受。	只在授权范围和指定版本上有效。
模型主张	候选原因、潜在风险、下一步建议。	属于待验证线索，不能单独触发通过。

每条证据的最小记录

```
evidence_id, task_id, run_id, attempt, producer
requirement_version, acceptance_version, policy_version
base_sha, head_sha, tree_hash, environment_fingerprint
command_id, started_at, ended_at, exit_code
artifact_ref, artifact_sha256, verdict, limitations
```

证据由执行器产生运行元数据，Agent 不能自行填造退出码。测试报告必须追溯到原始日志；内容哈希可检出产物变化，但不能证明报告本身真实或测试足够。关键测试由可信 runner 重新执行。

证据失效规则

代码、需求、验收、依赖或关键配置改变，相关证据失效；新的候选 SHA 默认重跑必需验收并审查。后续若做影响分析复用证据，必须有显式规则和可追踪依赖，第一版不做推测性复用。

11 / 表达确定程度，不等于成功概率

置信度为何不能作为验收

模型输出“置信度 95%”是自我报告，未必经过校准，也未定义概率事件。同一信息源、共同训练偏差和相似提示可能使多个模型同时犯错；相互赞同不能视为独立证据相乘。

看似可靠的信号	不能直接推出什么	应补充的依据
模型很自信	不能推出实现正确概率为 95%。	复现、需求映射、目标环境验收。
两种模型一致	不能推出独立双重验证。	不同证据来源与可核查的因果链。
测试覆盖率高	不能推出关键断言正确或需求齐备。	检查判题依据、遗漏场景与测试质量。
过去任务通过率高	不能推出新任务同样可靠。	任务类型、版本、风险与样本适用性。

允许怎样使用置信度

可以帮助安排核实顺序、提示人工关注或分配一次受限调查；不能覆盖缺失的必需证据。报告应分别列出需求充分性、验证覆盖、Review 完整性与环境代表性，避免用一个综合分掩盖短板。

如果未来确实需要概率决策

先定义事件，例如“下一轮后全部必需验收通过”；从带真值的历史 Trace 学习，按任务类别做校准，并在留出集检查预测与实际频率。模型、提示或任务分布变化后重新评估。小样本下保留不确定性，不用伪精确数值控制自动合并。

推荐的结果表述

“当前 SHA 的 12 项必需验收全部通过，2 项确认发现已修复；生产规模性能未验证，不能支持生产性能结论。”这比单报“置信度很高”更可操作。

12 / 先硬门禁，再考虑是否值得继续

Decision Framework：确定性规则

以下规则按优先级匹配。Controller 输出 decision、quality_verdict、stop_reason 和 evidence_refs；Hermes 可以提出候选行动，但不能修改预算、豁免关键项或替换决策证据。

优先级 / 条件	动作与含义
1. 用户取消 / 越权	终止进程并留存现场；CANCELLED 或策略阻断，绝不自动扩大权限。
2. 必需证据缺失、无效或版本错配	不能 PASS；保留已知 FAIL。允许一次有预算的证据修复；否则无已证实失败时为 UNKNOWN。
3. 有效证据证明失败	FAIL；若根因明确、允许修复且预算足够，进入 FIXING，否则结束并报告。
4. 关键争议或业务歧义	WAITING_HUMAN；冻结快照与预算上下文，等待明确决定。
5. 全部必需项通过、无未决阻断	PASS → READY；满足已约定的人工验收和交付条件后 DONE。
6. 尚未满足通过条件且触发限额/无进展	停止自动化；已证实错误保留 FAIL，否则 UNKNOWN；记录具体停止原因。
7. 其余可继续情况	必须说明下一步假设、预计新增证据、成本上界和成功/停止条件。

继续执行的价值判断

可以用“预期成功收益 - 下一轮成本 - 新增风险”组织思考，但成功概率不能直接取 LLM 自报置信度。第一版使用可解释规则：有新根因、有可验证行动、存在预算余量，且没有连续无进展或振荡。

若存在有效失败证据，同时又缺失其他必需证据，结论仍不得 PASS；保留已知 FAIL 与未验证项，不用一个标签抹掉事实。判断动作是否继续和判断质量是否通过，是两个不同问题。

13 / 运行状态、验收结论、停止原因分开

状态机与 UNKNOWN 终态

```
NEW -> CLARIFYING -> PLANNED -> IMPLEMENTING
    -> VERIFYING -> REVIEWING -> DECIDING

DECIDING -> FIXING -> VERIFYING -> REVIEWING
DECIDING -> READY -> DONE
DECIDING -> WAITING_HUMAN -> <revalidated state>
DECIDING -> STOPPED
Any active state -> CANCELLED / SYSTEM_ERROR
```

字段	枚举或示例	解释
run_status	READY / DONE / STOPPED / WAITING_HUMAN ...	流程运行到哪里；不代表质量结论。
quality_verdict	PASS / FAIL / UNKNOWN	针对指定需求与快照，证据支持何种结论。
stop_reason	BUDGET_EXHAUSTED / NO_PROGRESS / EVIDENCE_MISSING ...	为什么不能继续，便于人工接手与后续评估。

UNKNOWN 的适用场景

目标环境不可用、必要验收无法执行、业务含义未澄清、关键发现无法核实、输出不完整，或在限额内无法形成结论。UNKNOWN 表示“没有足够证据”，不是安全、失败或低置信度的同义词。

UNKNOWN 如何成为终态

自动化以 STOPPED + UNKNOWN 结束，保存当前提交、已通过/失败/未验证项目、证据缺口和建议下一步。不后台自动重启，不偷偷延长预算。人工给出新条件后创建关联的新 attempt 或运行；旧终态记录不可改写。

预算耗尽的两个例子

测试已证明跨租户泄露、修复未完成：STOPPED + FAIL + BUDGET_EXHAUSTED。测试环境始终不可用：STOPPED + UNKNOWN + BUDGET_EXHAUSTED。两者都不能报 DONE。

SYSTEM_ERROR 只描述执行系统故障；证据足够时保留已有质量结论，否则为 UNKNOWN。READY 表示候选可交付；DONE 表示任务约定的交付或集成动作确已完成。

14 / 预算必须覆盖所有模型循环

Token、时间、成本与轮次预算

以下是小任务试点起始值，非官方限制或通用最优配置。任务开始时冻结预算，统计 Hermes、双 CLI、额外核实调用与 CLI 内部重试；重新开会话不能重置任务总预算。

预算维度	试点建议	执行规则
候选与 Review	最多 3 个候选版本、3 次 Review；修复最多 2 次。	初版 H1 + 修复 H2/H3；每个新候选重新验证。
基础设施重试	每项操作最多 2 次重试。	仅瞬态故障可退避重试，仍计总时间与消耗。
总执行时间	自动执行 45 分钟；单个 CLI 最长 15 分钟。	包含排队、退避与测试；人工等待单列。
人工等待期限	默认 24 小时，可按任务调整。	不启动模型轮询；超期保存现场并结束等待。
Token 用量	总输入/输出用量起始上限 200k；80% 预警。	缓存分项计账；明确统计口径，不把缓存当免费。
费用与并发	费用上限 C 由任务指定；试点并发 1。	订阅调用不能直接按 API 单价当真实账单。

精确硬上限有现实限制

用量常在请求或轮次结束后才报告；CLI 可能内部重试，日志可能中断。无法保证精确 Token 硬上限时标为 BEST_EFFORT，记录统计缺口，不伪称已强制限制。可以真正由控制器强制的是截止时间、候选数、调用次数和并发上限。

预留下一轮与停止成本

启动前检查 remaining_budget ⩾ next_run_reservation + shutdown_reserve。CLI 支持单次费用限制时可作为第二道防线，不能代替任务级总账。达到硬限额后禁止新派单，终止整个进程组，保存现场；已在途请求可能已产生费用。

本机 Claude --help 含 --max-budget-usd，但未展示 --max-turns；不能直接复制旧 Skill 中的参数。第一版由控制器数轮次并管理超时，适配器只使用已核实能力。

15 / 可观察变化，而非 Agent 的积极表述

进展与收敛：下一轮是否值得

每轮保存相同口径的进展向量：必需验收通过数、确认阻断发现及影响、未决关键项、环境问题、失败根因指纹、已消耗资源。不同维度分别展示，不只给一个总分。

信号	如何判断	控制策略
有进展	原失败场景变通过，确认缺陷消除，或关键未知变成可验证根因。	预算允许且无新重大回归时，可继续。
表面活动	代码行数增加、长日志、总结更自信，但验证指标不变。	不计进展；要求下一步可证伪假设。
停滞	连续 2 个候选周期未减少失败/阻断或关键未知。	NO_PROGRESS；停止或转人工，不能盲目再试。
振荡	同一根因反复出现，或 A 修复引入 B、B 修复恢复 A。	记录根因指纹和树差异；确认循环则停止。
回归	新出现关键失败，或已解决阻断重新出现。	优先核实回归；不得用其他通过数抵消。

“收敛”和“完成”的区别

收敛表示已知阻断项持续减少且没有重要回归，只支持继续投入的判断；完成仍要求全部必需门禁通过。最后一项可能是最难的一项，不能用“90% 已完成”推断很快成功。

去重与抗噪声

以根因 + 触发条件 + 影响路径形成稳定 finding 指纹；行号变化不算新发现。基础设施失败与业务失败分开；对于疑似 flaky 测试按预设次数复现，保留每次结果，不挑选一次通过来清除失败。

有效的继续理由

“失败已定位到区间右边界；下一轮仅调整比较条件，并重跑 AC-03 与筛选回归，预计 5 分钟。”若只有“再试一次可能更好”，证据不足以支持自动延长。

16 / 明确负责人、问题和可恢复上下文

人机协同：把人用在判断上

人工介入用于澄清业务语义、核实关键争议、接受残余风险、调整预算及授权外部动作。不要把每条常规测试失败都交给用户，也不要让 Hermes 以自信总结代替应由用户决定的事项。

触发条件	给人工的决策包	允许的返回
关键需求歧义	两种解释、受影响验收项、建议默认值。	选择语义或修订需求版本。
高影响发现无法核实	最小复现、正反证、缺失环境、风险。	补充环境、裁决或接受指定残余风险。
预算不足 / 停滞	资源消耗、已取得进展、下一步上界与收益依据。	追加固定预算、缩小范围或停止。
合并 / 发布 / 数据操作	候选 SHA、验证摘要、目标、回滚方案。	按已授权策略执行，或拒绝。

人工决策必须绑定版本

记录 decision_id、责任人、时间、需求/策略版本、head_sha、范围和理由。等待期间冻结候选；新提交、需求或关键配置变化后重新判断该决策是否适用。不能把一次授权扩展到后续任意版本。

风险接受不伪装成测试通过

人工可以按权限接受某项未验证风险，但原始证据仍记录为未验证。必要时生成新版验收政策并重新评估，清楚列出豁免，不把“人工同意”改写为“测试成功”。

等待与恢复

WAITING_HUMAN 期间停止自动修复与模型调用。保存未完成的问题和可选行动；用户答复后校验版本、权限、环境与预算，再恢复。超期可形成 STOPPED + UNKNOWN，便于稍后明确接手。

17 / 保留原版恢复设计，核对当前命令

CLI 会话：显式 ID 与受控适配

task_id、Hermes 对话 ID、Codex thread_id、Claude session_id 分别存储；编码会话与审查会话独立。恢复时核对仓库、角色、cwd、身份、CLI 版本与权限策略；并发任务不用 --last 或 --continue。

Codex CLI：首次执行与修复 [3]

```
codex exec -C /work/task-001 --sandbox workspace-write \
  --json --output-schema /contracts/coding.json \
  -o /artifacts/coding.json "Implement the frozen task"

codex exec -C /work/task-001 --sandbox workspace-write \
  --json resume <CODEX_SESSION_ID> "Fix confirmed findings"
```

首次从 thread.started 读取 thread_id；--json 是事件流，--output-schema 约束最终输出。不要启用 --ephemeral。恢复前重新施加策略；最终 JSON 通过 Schema 校验仍不代表任务验收通过。

Claude Code CLI：独立只读 Review [4]

```
claude -p "Review the frozen snapshot and acceptance" \
  --output-format json --tools "Read,Glob,Grep" \
  --disallowedTools "mcp__*" --permission-mode dontAsk

claude -p "Review the new snapshot and prior findings" \
  --resume <CLAUDE_SESSION_ID> --output-format json \
  --tools "Read,Glob,Grep" --disallowedTools "mcp__*" \
  --permission-mode dontAsk
```

Executor 设置 cwd、准备 patch/源码/契约并读取 session_id。需要结构化最终结果时配置经校验的 --json-schema；从 structured_output 提取报告。--tools 控制内置工具集，MCP、Hook、插件和 OS 权限仍需独立限制。

会话恢复失败

按会话加锁；丢失或不兼容时不恢复到别的任务。生成目标、基线、候选、未决项和证据简报，新建会话并记录旧 ID → 新 ID。命令为示意，路径及占位 ID 由适配器替换；本次未启动实际模型任务。

18 / 保留原版隔离与快照设计

Worktree、只读审查与固定 SHA

每个编码任务分配独立分支和 worktree，记录不可变 base_sha。编码者完成当前版本后停止写入，检查未提交和未跟踪文件，生成 head_sha 与 tree_hash。测试、Review 与验收必须指向同一快照。

```
git -C /repos/project worktree add \
  -b agent/task-001 /work/task-001 <BASE_SHA>

git -C /repos/project worktree add --detach \
  /review/task-001-r1 <HEAD_SHA>

git -C /repos/project diff --no-ext-diff --no-textconv \
  <BASE_SHA> <HEAD_SHA> --
```

交接步骤	不可跳过的检查
实现 → 冻结	必要文件已保存；候选可追踪；未提交内容不藏在报告外。
冻结 → 验证	可信 runner 在固定内容上运行；记录环境指纹和原始结果。
验证 → 审查	只读读取当前候选、基线差异和需求契约，保存 reviewed_sha。
修复 → 新候选	产生新 SHA；旧通过证据不能直接覆盖新提交，重新验收与审查。
READY → 集成	基线变化后补充冲突处理与集成验证；按授权动作交付。

Worktree 的能力边界 [6]

worktree 隔离目录，但共享 Git 对象和部分管理信息；detached worktree 仍然可写。只读审查采用只读挂载、独立身份或导出快照，不能仅凭不同目录保证安全。端口、数据库、缓存、网络和凭据也要按任务隔离。

测试代码和依赖脚本可执行任意行为；验证 runner 使用隔离测试身份与最小挂载。清理前停止进程、留存提交和产物，不强删仍有未保存修改的工作区。

19 / 固定接口，模型不得传任意命令

受控 Executor 与数据契约

接口示意	服务端校验与返回
start / resume	task_id、角色、brief_ref、幂等键；服务端解析目录、会话和策略，返回 run_id。
freeze / review / verify	解析 snapshot_id，绑定需求与验收版本；选择已登记的执行器和验证计划。
status / cancel	返回事实、用量和证据索引；取消整个进程组，操作可重复调用。
decide / request_human	按确定性优先级决策；生成带版本的人工决策包。

结果封装示意：由执行器补齐事实字段

```
{
  "task_id": "T-001", "run_id": "R-003", "attempt": 2,
  "role": "review", "snapshot_id": "S-002",
  "head_sha": "<head>", "reviewed_sha": "<head>",
  "requirement_version": 1, "acceptance_version": 1,
  "findings": [{
    "id": "F-01", "state": "UNRESOLVED",
    "severity": "high", "acceptance_id": "AC-02",
    "file": "src/export.ts", "line": 42,
    "claim": "<trigger and impact>",
    "evidence_refs": ["EV-013"]
  }],
  "artifact_refs": ["review.json", "runner.log"]
}
```

校验不止 Schema

检查枚举、路径边界、行号、SHA、产物存在性、哈希、执行身份与报告完整性。空 findings 只有在审查正常完成、范围齐全且所有验收有效时才有意义；缺字段、截断或异常退出不能被当作“无问题”。

命令使用固定可执行文件和参数数组；repo_id、snapshot_id 等由服务端解析。拒绝模型传任意 Shell、环境变量、路径或报告内命令。接口与字段是本方案建议，不是 Hermes 或 CLI 内置 API。

持久化、崩溃恢复与故障注入

第一版用 SQLite 保存 tasks、runs、sessions、snapshots、evidence、findings、decisions、budget_events；日志和报告置于独立产物区。事务化更新状态和事件；不可变产物用内容哈希索引，保留策略、CLI 和 Skill 版本。

故障	恢复规则
Controller / Hermes 重启	先对账运行租约、进程身份、工作区、最后事件和用量；不重复派发仍活跃的任务。
Worker 被杀 / 无响应	按截止时间停止进程组；保留未完成输出，质量结论不得自动通过。
旧结果迟到	使用 attempt 和 fencing token 拒绝过期 Worker 更新当前任务。
CLI 输出截断 / Schema 错误	记为无效结果；最多进行有预算的格式或证据重建，不能补造成功。
会话丢失 / 工作区漂移	停止自动恢复，校验内容与快照；必要时新建会话，记录完整迁移链。
限流 / 鉴权失败	限流按有界退避；鉴权错误交给配置处理，不循环重登或扩大权限。

进程与重复操作

PID 可能复用，不能单凭 PID 判断原任务存活；结合进程启动时间、租约与 run_id。系统不承诺“恰好一次执行”，重试前检查已落地提交、产物与外部动作，以幂等键和对账降低重复风险。

第一版必须注入的异常

断网、卡死、CLI 非零退出、空报告、会话文件丢失、旧 SHA 报告迟到、预算刚好耗尽、用户取消、磁盘写入失败及基线变化。逐一检查终态、残留子进程、证据保留和能否人工接手。

框架引入时机

SQLite + 本地控制器足以验证单任务。只有当跨机器恢复、长时间等待或并发复杂度成为真实瓶颈时，再评估 LangGraph / Temporal；它们提供执行基础设施，不自动提供正确的业务验收与停止政策。

完整案例：导出订单的受控闭环

阶段	本次证据与判断	结果
需求澄清	用户确认仅当前租户、时间右边界不包含结束时刻；冻结 AC-01 至 AC-05。	允许实现；体验验收由用户负责。
候选 H1	正常导出通过；独立验收发现跨租户数据泄露。	有效失败 → FAIL；可修复。
Review H1	F1：缺租户过滤，复现确认；F2：声称 CSV 引号处理错误，解析反证成立。	F1 CONFIRMED；F2 REFUTED，保留反证。
修复 H2	加租户过滤；AC-01 至 AC-04 通过，复审无未决阻断。	有进展；体验证据仍缺失。
人工验收	用户在候选 H2 演示中确认入口与状态满足 AC-05。	全部门禁满足 → PASS / READY。
交付	保存 H2 补丁、证据、Review 处置、预算与未验证范围。	按任务约定交付后 DONE。

三个分支，三个不同结论

分支 A：H2 仍泄露数据且预算耗尽。 STOPPED + FAIL；不能因“已修复大部分”交付为成功。

分支 B：数据环境不可用，AC-02 无法执行。 即便模型一致认为过滤正确，若无足够替代证据，仍为 STOPPED + UNKNOWN。

分支 C：用户改变时间边界语义。 创建需求/验收新版本，分析 H2 影响并重新验证；旧证据只支持旧契约。

本案例的关键

一个真实缺陷不因误报存在而被忽略，一个误报也不因审查者自信而被修复；缺少体验验收时不提前完成。每次判断都能追溯到同一版本的证据。

分阶段落地：先验证，再增加智能

阶段	交付范围	进入下一阶段的门槛
0. 能力核对	核实 CLI-only 范围、账号权限、版本参数、非交互输出、会话恢复、隔离方式。	两种 CLI 在实验仓库可独立运行；不依赖 SDK，费用口径清楚。
1. 双 CLI 最小闭环	纯 Python Controller；单仓库单任务、固定角色、冻结 SHA、独立验收、有限循环。	正常路径完成；失败/UNKNOWN/取消可复查；不覆盖用户改动。
2. 可靠性与证据	SQLite、租约、进程组、预算、发现核实、人工等待、故障注入。	重启不串会话；旧结果无效；停机与恢复证据完整。
3. 接入 Hermes	受控编排接口、需求草案、计划建议和证据解释；禁用源码编辑与任意 Shell。	确认协调模型入口合规可用；不能绕过控制器门禁；收益超过新增成本。
4. 受控并发与优化	队列、资源隔离、串行集成；历史 Trace 评测与策略改进。	多任务无串扰；重复评测显示质量/成本收益，取消清理可靠。

第一版明确不做

不叠加 Open SWE；不引入 SDK 或 App Server；不做无限自动改写、模型自由修改验收、无人约束的自动合并或大规模并发。需要这些能力时通过具体任务和评测决定扩展。

两个长期闭环

执行闭环：实现 → 审查 → 验证 → 决策，解决当前任务。
优化闭环：Trace → 根因分析 → 政策变更 → 留出集评测，改善未来任务。政策升级需要版本、回归和回退点，不直接在运行任务上改变判题依据。

实施按验收门槛推进，不以固定工期代替验证。Hermes 是目标协调层，但第一阶段暂不接入它，可以降低验证双 CLI 协作假设的难度。

系统验收与投入判断

验收维度	必须观察到的结果
权限边界	Hermes 无法直接写源码；审查环境写入被拒；报告内命令不被执行。
会话与版本	显式 ID 不串任务；测试与审查绑定当前候选；过期结果不推进状态。
证据有效性	0 测试、关键跳过、截断、无原始日志及错误 SHA 均不能 PASS。
停止与预算	超时、取消、轮次耗尽、停滞后停止进程组；不重新开会话重置预算。
UNKNOWN	缺环境或关键证据时能结束为 UNKNOWN；保存缺口和人工接手材料。
人工与恢复	等待时不循环调用模型；答复绑定版本；重启后恢复或保守停止。
隔离与清理	两个任务不共享可冲突资源；清理不丢未保存修改和必要产物。

试点评测建议

先收集 10-20 个覆盖 Bug、功能、重构和含糊需求的小任务作为探索集，并加入正确对照与故障场景。这个规模只适合发现问题，不能支撑稳定的成功率保证；扩展样本后再决定默认自动化范围。

同时报告质量、成本与人工负担

端到端验收通过率、严重缺陷漏报、Review 查准率与未决率、UNKNOWN 比例及原因、人工介入次数/分钟数、总用量、端到端耗时、重复执行与新增回归。比较相同任务和预算，明确是否包含失败任务。

值得继续投入的标准

相比人工协调或 Codex 单独工作，取得可重复的质量或人工时间收益，且新增审查与协调成本可接受。若只是报告更长、轮次更多，不能视为成功。

没有样本结果时，本文件只给出验证方案与设计建议，不给出多 Agent 成功率、成本降低比例或 Review 召回率的承诺。

24 / 保留原版风险清单，补齐质量边界

风险、边界与交付检查

风险	主要措施与剩余限制
提示注入与越权	源码、日志和报告视为数据；结构化接口 + 权限隔离。模型仍可能漏报或误解。
测试/凭据泄露	测试身份隔离、最小挂载与网络限制、脱敏日志；父进程清理变量不足以隔离所有凭据。
同源错误与伪成功	独立验收、反例、可信 runner；多模型一致与高覆盖率均不能证明全面正确。
误报修复与回归	发现先核实再修复；新候选重验，不以问题数量考核 Review。
版本与配置漂移	固定 CLI / Skill / Hook / 插件与策略版本；升级前做契约和恢复回归。
成本与恢复空转	任务级预算覆盖全部调用；证据不足、停滞与振荡有明确终态。
并发与集成冲突	租约、任务锁、资源分配与串行集成；worktree 不构成完整安全沙箱。

交付包最小内容

① 需求与验收版本、范围与假设。② 基线/候选 SHA、补丁与工作区状态。③ 每项验收结果、环境、命令与原始证据。④ Review 发现及核实、反证、修复或豁免。⑤ 运行状态、质量结论、停止原因与未验证范围。⑥ 用量、耗时、轮次、统计缺口与人工决策。⑦ 集成状态、恢复方法及下一步。

保留真实边界

软件任务没有通用、全自动、完备的正确性判定器。本文通过明确契约、证据和可终止流程降低风险；剩余业务歧义和难验证风险交给指定人工。自动化失败或 UNKNOWN 都应被保留为有效评测结果。

对用户的结果汇报

先报告质量结论与交付状态，再列证据覆盖和未解决项。停止时说明原因、当前成果、需要人工决定什么；不得将预算耗尽描述成任务完成。

25 / 原文沿用范围及官方能力依据

资料来源与核对记录

原文与续接上下文

原版文件：Hermes_Codex_Claude_Code_纯协调层架构方案.pdf；10 页，2026-10-09。已核对 Downloads、Documents 与此前 Work 输出中的副本，并读取原版生成源文件。本版为内容修订与重新排版，未覆盖原文件。

原版章节映射：架构与集成 → 03/04；职责与 Skill → 03/19/24；会话恢复 → 17；worktree → 18；状态机 → 12/13；Executor 与恢复 → 19/20；实施 → 22；风险 → 24；验收与资料 → 23/25。新增重点为 05-16 与完整案例 21。

续接会话：《枚举实用案例》，conversationId：6ac85323-a6ec-83ea-924b-9a2a1a1a2bf7。已读取可访问的近期记录；其中既有技术主张作为背景，当前能力依据下列官方资料和本机帮助核对。

本次核对范围

日期：2026-10-09。本机只读核对 Codex CLI 0.161.0、Claude Code 2.1.286 的版本与帮助输出；未启动真实编码/Review、未验证登录或计费、未检查或修改本机 Hermes 配置。命令示例不是已运行结果。

官方参考资料（可点击）

[1] Hermes：Codex 委派 Skill
https://github.com/NousResearch/hermes-agent/blob/main/skills/autonomous-ai-agents/codex/SKILL.md

[2] Hermes：Claude Code 委派 Skill
https://github.com/NousResearch/hermes-agent/blob/main/skills/autonomous-ai-agents/claude-code/SKILL.md

[3] OpenAI：Non-interactive mode
https://learn.chatgpt.com/docs/non-interactive-mode

[4] Claude Code：Run programmatically
https://code.claude.com/docs/en/headless

[5] Open SWE：官方项目与架构说明
https://github.com/langchain-ai/open-swe

[6] Git：git-worktree
https://git-scm.com/docs/git-worktree

来源边界：上述资料支持 CLI 与框架的能力事实；任务契约、证据账本、状态、接口、预算、评分与阶段门槛均为本方案设计建议，需通过试点评测。官方文档和 Skill 可能变化，实施时以固定版本的帮助与实际契约测试为准。